

과목명	머신러닝프로그래밍				
평가 내용	2023년도 1학기 기말프로젝트 중간보고서				
프로그램명	야, 인공지능! 너가 감히 내가 쓴 손글씨를 맞출 수 있을까?				
학생 정보	팀장	학번	201904010	이름	박범찬
	팀원	학번	201904022	이름	이기현
		학번	202104003	이름	김나영

1. 프로그램 목적 및 기대효과

프로그램 필요성

스마트폰이나 태블릿 등 전자기기에서는 손글씨를 인식하는 기능이 지원되는 경우가 많으나, 글씨가 불규칙적일 경우 인식에 실패하는 경우가 종종 발생한다. 페이스 아이디나 지문 인식 등을 통해 예민한 개인정보를 보안하는데 널리 사용하지만, 여전히 인식의 문제나 데이터의 오류가 빈번하게 일어나고 있는 상황이다.

우리의 이러한 소규모 프로젝트로는 당연히 이러한 문제점들을 해결할 수는 없겠지만 어쨌거나 여기서 가장 핵심은 손글씨 인식을 위한 가장 기초적인 딥러닝에서 CNN파트인 MNIST 프로젝트를 만들어 봄으로써, 데이터의 분류와 인식, 그리고 학습 등을 연구할 수 있는 첫 발판이 될 것이다.

프로그램 소개

목적 : MNIST 데이터셋과 CNN 알고리즘을 활용하여 높은 확률로 해당 손글씨를 인식하는 것이 주된 목적이며, 나아가 형상화된 동작이나 점선 등을 인식하는 것 까지 도전과제로 삼았다.

요약 : 사용자로부터 손글씨 이미지 파일 혹은 손글씨를 형상화 한 손동작 이미지를 데이터로 입력받고, 해당 이미지가 무슨 글씨인지 결과값을 출력해준다.

기대효과 : 본 프로그램을 통하여 손글씨를 인식하는 데에 있어서 정확도 향상을 기대 할 수 있으며, 전자기기에서의 손글씨 인식의 쓰임새와 편리성이 더욱 더 확장되는 효과를 기대 할 수 있고, 더 나아가 손글씨 뿐만 아니라, 사람의 동작 등을 인식하는 프로그램으로의 발전 또한 기대 할 수 있다.

2. 데이터

(1) 출처

MNIST(Mixed National Institute of Standards and Technology) 데이터셋은 미국 표준기술연구소(NIST)에서 원래 수집한 데이터를 바탕으로 만들어진 것이다.

원래 NIST 데이터셋은 훈련 데이터와 테스트 데이터를 미국 인구의 다른 부분에서 수집했지만, MNIST 데이터셋은 이를 재구성하여 훈련 데이터와 테스트 데이터가 같은 분포를 가지도록 만들었다. 이렇게 하면 머신러닝 모델이 훈련 데이터에만 특화되는 과적합을 방지할 수 있다.

(2) 데이터 요약

인덱스	이름	데이터 타입	값	설명
0	5	범주형	5	훈련 데이터 0번째 손글씨
59999	8	범주형	8	훈련 데이터 59999번째 손글씨
60000	7	범주형	7	테스트 데이터 0번째 손글씨
69999	6	범주형	6	테스트 데이터 9999번째 손글씨

3. 알고리즘

MNIST 데이터셋 자체에는 특정 알고리즘이 내장되어 있지 않다. 대신, 이 데이터셋은 다양한 머신러닝과 딥러닝 알고리즘을 테스트하고 학습하는 데 널리 사용된다.

따라서 사용되는 알고리즘은 데이터셋을 사용하는 연구자나 개발자가 선택한다.

1) 신경망(Neural Networks):

신경망은 인간의 두뇌에서 영감을 얻은 방식으로 데이터를 처리하도록 컴퓨터를 가르치는 인공지능 방식이다. 인간의 두뇌와 비슷한 계층 구조로 상호 연결된 노드 또는 뉴런을 사용하는 딥러닝이라고 불리는 기계 학습 과정의 유형이다. 신경망은 컴퓨터가 실수에서 배우고 지속적으로 개선하는 데 사용하는 적응형 시스템을 생성한다. 따라서 인공신경망은 문서 요약 또는 얼굴 인식과 같은 복잡한 문제를 더 정확하게 해결하려고 한다.

장점

1. 복잡한 문제 해결: 딥러닝 신경망은 복잡한 문제를 해결하는 데 강점을 가지고 있다. 깊은 구조와 다양한 레이어로 구성된 신경망은 다양한 특징을 추출하고 데이터의 복잡한 패턴을 학습할 수 있다.
2. 자동 특징 추출: 딥러닝 신경망은 입력 데이터로부터 자동으로 특징을 추출할 수 있다. 기존의 머신러닝 알고리즘은 사람이 수동으로 특징을 설계해야 했지만, 딥러닝은 데이터로부터 자동으로 학습하므로 특징 공학에 대한 의존도가 낮다.
3. 대용량 데이터 처리: 딥러닝은 대용량의 데이터를 처리하는 데 능숙하다. 신경망은 수백만 개 이상의 매개변수를 가질 수 있으며, 이를 효과적으로 학습시킬 수 있다. 이는 대규모 데이터셋에서 더 정확한 예측을 가능하게 한다.

단점

1. 계산 비용과 시간: 딥러닝 신경망은 많은 계산 리소스를 필요로 한다. 많은 수의 레이어와 매개변수를 가진 신경망은 학습과 추론에 많은 계산 비용과 시간이 소요될 수 있다. 이는 하드웨어 요구사항이 높아지는 단점으로 작용할 수 있다.
2. 데이터 요구사항: 딥러닝은 많은 양의 레이블이 있는 훈련 데이터를 필요로 한다. 충분한 양의 데이터를 수집하고 레이블을 달기 위한 작업은 비용과 시간이 많이 소요될 수 있다. 데이터가 부족하거나 품질이 낮으면 신경망의 성능이 저하될 수 있다.
3. 해석 가능성의 어려움: 딥러닝 신경망은 학습된 모델의 내부 동작을 이해하고 해석하기 어려울 수 있다. 복잡한 구조와 많은 수의 매개변수로 인해 모델의 결정 과정을 설명하기 어렵고, 특정 예측을 왜 이뤄내었는지를 명확하게 이해하기 어렵다.

신경망에서 Hidden layer의 활성화 함수로 ReLu 함수를 사용하여 이진 분류를 한 뒤, Output layer에 Softmax 함수를 통해 확률 나타낸다.

Q. 이진 분류라면, 시그모이드 함수가 아닌 왜 렐루 함수를 사용했을까?

A. 1. 기울기 소실 방지 : Sigmoid 입력값이 극단적일 경우, 기울기가 0에 가까워진다 (= 학습이 매우 느리고, 신경망이 수렴하기 어려움)

그러므로 ReLU는 양수 입력 값에 대해 일정한 기울기를 갖고 있으므로 이 문제를 방지할 수 있다

2. 계산의 효율성 : Sigmoid는 지수 함수가 포함되기 때문에 나눗셈 같은 복잡한 수학적 연산이 필요하다. 그에 반해, ReLU는 간단하게 계산할 수 있기 때문에 계산 효율성을 높일 수 있고 이는 훈련 프로세스를 더 빠르게 만들고 최적의 값으로 수렴하는 속도도 높여줄 수 있다.

여러 장점이 있지만 여전히 ReLU 함수 또한, 단점은 있다. 입력값이 음수인 경우 기울기가 0이 되어 가중치 업데이트가 안될 수 있다.(죽은 렐루 현상) 따라서 이를 해결하기 위해 Leaky ReLU 함수가 등장하기도 했다.

MNIST 데이터셋은 이미지 분류 작업에 사용되기 때문에, 일반적으로 CNN과 같은 이미지 처리에 특화된 알고리즘이 더 효과적인 결과를 보여주는 경향이 있다.

그러나, 이는 여전히 데이터셋의 특성, 문제 정의, 그리고 학습 프로세스의 특정 세부 사항에 따라 달라질 수 있다.

4. 순서도

